

Техническое задание

Система подбора аналогов товаров на маркетплейсах

Обозначение документа: ТЗ МПА 001. Версия: 1.0. Дата: 09 октября 2026 года.

Документ устанавливает требования к разработке системы, которая по ссылке на исходный товар находит тот же товар и функциональные аналоги на других маркетплейсах, объясняет соответствие и позволяет сравнить актуальные предложения. Первая версия должна обеспечивать завершённый пользовательский сценарий и сокращать ручной поиск без сложной инфраструктуры и обязательного применения машинного обучения.

Состав поставки MVP: Python backend и парсеры, PostgreSQL, REST API, веб-интерфейс, автоматическая обработка задач, история результатов и набор проверок качества. Основным интерфейсом MVP — веб-приложение. Расширение Chrome и публичный многопользовательский сервис предусматриваются на следующих этапах.

Лист согласования

Заказчик: _____. Представитель заказчика: _____.

Исполнитель: _____. Представитель исполнителя: _____.

Утверждение заказчиком: подпись _____, дата _____.

Согласование исполнителем: подпись _____, дата _____.

Изменение границ MVP, состава площадок, поддерживаемых категорий и критериев приёмки оформляется согласованной новой версией документа. Численные показатели настоящего ТЗ являются требованиями к будущей реализации, а не характеристиками существующего прототипа.

Содержание

1 Общие сведения	3
2 Назначение и цели	4
3 Границы MVP	4
4 Пользовательские сценарии	5
5 Функциональные требования	6
6 Подбор аналогов	7
7 Сбор данных и устойчивость	9
8 Архитектура и реализация	10
9 Модель PostgreSQL	11
10 API	13
11 Веб и развитие интерфейсов	14
12 Нефункциональные требования	14
13 Проверки качества и приёмка	15
14 Порядок разработки	17
15 Сокращение трудозатрат и оптимизация	18
16 Риски и ограничения	19
17 Состав поставки и приёмочные документы	19
18 Последующее развитие	20
Приложение А Источники технических решений	20

1 Общие сведения

1.1 Наименование и основание разработки

Наименование: система подбора аналогов товаров на маркетплейсах. Основание: необходимость автоматизировать поиск сопоставимых товаров и сравнение предложений нескольких площадок. Существующий проект parser используется как исходный прототип браузерного сбора данных Ozon.

Заказчик принимает требования и контрольный набор. Исполнитель отвечает за реализацию, испытания, развёртывание и эксплуатационную документацию. Конкретные юридические лица и сроки утверждаются на листе согласования и в календарном плане.

1.2 Предлагаемая конфигурация MVP

Перечень площадок: Ozon, Wildberries, Яндекс Маркет. Этот состав принимается как базовая конфигурация для планирования; замена третьей площадки допускается до начала разработки её адаптера. Приёмка полной версии MVP требует работоспособных адаптеров всех трёх согласованных площадок.

Первая поддерживаемая категория: потребительские наушники и гарнитуры. В её пределах поддерживаются проводные, беспроводные и игровые модели. Принадлежности, сменные амбушюры, зарядные кейсы без наушников, ремонтные детали, комплекты из нескольких независимых товаров и б/у товары не включаются в подбор по умолчанию.

Ограничение одной категорией позволяет качественно нормализовать характеристики и проверить подбор без разработки универсальной онтологии всего каталога. Архитектура должна позволять добавлять категории посредством правил и адаптеров, без переписывания API и схемы поиска.

1.3 Термины

Термин	Определение
Исходный товар	Товар, выбранный пользователем как основание поиска
Точное совпадение	Тот же товар и вариант, подтверждённый идентификаторами и значимыми характеристиками
Вариант товара	Цвет, объём, размер, комплектация либо иные отличия одной модели
Функциональный аналог	Другой товар той же категории, удовлетворяющий обязательным условиям пользователя
Кандидат	Карточка, полученная поиском до проверки соответствия
Карточка	Представление товара на конкретной площадке с её внешним ID
Наблюдение	Полученная цена и состояние карточки для определённых времени, региона и условий
Свежие данные	Данные, возраст которых не превышает установленный TTL
Задача подбора	Сохраняемый запрос со статусом, исходным товаром, фильтрами и результатами

Термин	Определение
Адаптер	Модуль доступа и извлечения данных конкретной площадки
Покрытие признаков	Доля сравниваемых характеристик, подтверждённых у обеих карточек

2 Назначение и цели

2.1 Назначение

Система предназначена для пользователя, выбирающего альтернативное предложение товара либо замену с близкими характеристиками. Она должна автоматизировать получение исходных данных, поиск кандидатов, их нормализацию, проверку соответствия, ранжирование и обновление цен.

Поддерживаются два отдельных режима: «Тот же товар» и «Подобрать аналог». Пользователь выбирает режим явно. Отображение режима и причин соответствия обязательно для каждого результата.

2.2 Целевые показатели

На фиксированном контрольном наборе: средняя точность выдачи функциональных аналогов Precision@5 не ниже 0,90; хотя бы один релевантный результат в первых пяти для не менее 85% проверочных запросов с заранее известным доступным аналогом. Для режима точного совпадения не допускается ни одного неверного уверенного совпадения на проверочном наборе.

В пилотной эксплуатации не менее 90% допустимых задач должны завершаться без участия оператора при доступных источниках. Доступность источников оценивается отдельно; ошибки 403 нельзя исключать из общего отчёта успешности. Поисковые, сетевые и алгоритмические метрики должны публиковаться отдельно.

Цель сокращения ручной работы — не менее 70% относительно ручного поиска в тех же сценариях. Замер производится на 10 одинаковых сценариях: от получения ссылки до списка из трёх проверенных вариантов. Требование подтверждается пилотом, а не предположением о скорости автоматизации.

3 Границы MVP

3.1 Обязательный объём

- Получение исходного товара по URL с каждой из трёх площадок.
- Подтверждение и редактирование характеристик исходного товара пользователем.
- Два режима сопоставления и исключение конфликтующих кандидатов.
- Поиск на двух остальных площадках с сохранением статусов каждой.
- До 10 результатов на площадку после дедупликации, фильтры и сортировка.
- Объяснение результата и неизвестных характеристик.
- Сравнение цен только с учётом региона, валюты, условий и времени.
- Сохраняемые задачи, повторный подбор, избранные результаты и экспорт CSV.

- Плановое обновление избранных карточек, диагностика источников и повтор временных ошибок.
- REST API и простой адаптивный веб-интерфейс на русском языке.
- Авторизация владельца установки и ограничение доступа к API.
- Восстановление задач после перезапуска и документированное резервное копирование.

3.2 За пределами MVP

Мобильное приложение, Chrome-расширение, массовый обход всего каталога, полнотекстовое содержание отзывов, рекомендации по изображениям, OCR, обучение нейросети, обязательные внешние LLM, покупка и оплата товаров, учёт персональных скидок, мультирегиональный публичный сервис и сложное управление организациями не входят в MVP.

MVP предусматривает одного владельца установки и один регион по умолчанию. Модель региона должна присутствовать в данных; смена региона создаёт отдельный контекст наблюдений. Рейтинг и количество отзывов используются при доступности, но неизвестные значения не подменяются нулём.

3.3 Критерий уверенного продукта

Для пользователя доступен один завершённый маршрут от ссылки до объяснимого списка аналогов. Ошибки источников показаны отдельно; сохранённый результат не теряется; статус задачи понятен; сравнение цен не содержит скрытых условий. Данные и результат можно воспроизвести по версии алгоритма и сохранённым наблюдениям.

4 Пользовательские сценарии

4.1 Основной сценарий

1. Пользователь вводит URL исходного товара и выбирает режим.
2. Система проверяет адрес, определяет площадку и извлекает карточку.
3. Пользователь видит название, вариант и ключевые характеристики; при необходимости исправляет неизвестные поля и задаёт обязательные условия.
4. После подтверждения система использует локальный кеш и при необходимости запускает поиск на остальных площадках.
5. Интерфейс показывает ход задачи и статусы источников без блокирования страницы.
6. Пользователь получает список с ценами, оценкой сходства, причинами, различиями и временем обновления.
7. Пользователь применяет фильтры, открывает оригинальную карточку, сохраняет результат либо выгружает CSV.

Подтверждение исходных характеристик допускается пропускать при повторном запросе с неизменной сохранённой моделью и достаточными данными. Если обязательная характеристика не установлена, задача переходит в `needs_input`; интерфейс перечисляет требуемые поля.

4.2 Недоступность площадки

Если один целевой источник недоступен, результат доступного источника публикуется со статусом `partial`. Для недоступного источника показывается причина, время проверки и возможность повторить его отдельно. Пустой список не выдаётся как доказательство отсутствия аналогов.

Если не удалось загрузить исходный товар, пользователь может внести название и обязательные характеристики вручную. Такой ввод сохраняется с происхождением `manual`; он не считается подтверждённым извлечением карточки. Блокировка источника не должна маскироваться ручным вводом в отчёте доступности.

4.3 Обновление

Повторный запрос с тем же контекстом использует свежие данные. Избранные карточки обновляются раз в 24 часа по умолчанию. В интерфейсе доступна команда обновления; не более одной активной задачи для одинаковой карточки и контекста.

5 Функциональные требования

5.1 Приём запроса

FR-01. Поддерживать URL карточки и ручной ввод структурированных характеристик. URL поиска не является основным пользовательским входом, но используется адаптерами для получения кандидатов.

FR-02. Нормализовать URL, определить источник и внешний ID, исключить параметры рекламы из ключа дедупликации. Отсутствие известного ID допускает резервный ключ по каноническому URL с отдельной отметкой.

FR-03. Проверять обязательные поля до запуска поиска. Неподдерживаемые площадки и категории отклонять понятным сообщением; не интерпретировать их как отсутствие кандидатов.

5.2 Получение исходного товара

FR-04. Извлекать название, бренд, модель, категорию, вариант, URL, цену и её текст, валюту, время наблюдения. Регион, наличие, рейтинг, количество отзывов и характеристики сохранять при достоверном получении.

FR-05. Для каждого значимого поля сохранять происхождение: `structured_data`, `dom`, `manual` либо `inferred`. Предположения не должны использоваться как подтверждение точного совпадения.

FR-06. Поддерживать работу со страницами отдельных товаров. Существующий прототип, который отклоняет `/product/`, должен быть расширен отдельным методом `fetch_product`.

5.3 Поиск и получение кандидатов

FR-07. Формировать не более трёх запросов на целевую площадку: бренд и модель; очищенное название; категория и обязательные признаки. Запросы выполняются последовательно с досрочным завершением при достаточном числе качественных результатов.

FR-08. По умолчанию просматривать максимум две страницы одного поискового запроса и накапливать не более 60 уникальных кандидатов на площадку. Верхние пределы задаются конфигурацией; источник может вернуть меньше результатов.

FR-09. Сначала обрабатывать данные выдачи. Дополнительные карточки открывать только для лучших предварительных кандидатов: максимум 10 на площадку. Для режима точного совпадения подтверждение значимых признаков обязательно.

FR-10. Удалять повторы по площадке и ID; в пользовательской выдаче объединять карточки одного подтверждённого варианта на одной площадке, сохраняя отдельные ссылки на предложения. При отсутствии доказательства идентичности карточки не объединять.

5.4 Представление результата

FR-11. Для каждой позиции показывать площадку, название, ссылку, доступную цену, условия цены, регион, время получения, тип соответствия, балл, совпавшие признаки, различия и неизвестные данные.

FR-12. Цена с картой или подпиской выделяется явно. При неизвестных условиях запрещена отметка «самое выгодное предложение». Стоимость доставки и персональные скидки не включаются в итоговую экономию MVP.

FR-13. Результаты ранжируются по соответствию; при одинаковой оценке — по полноте подтверждения и свежести. Цена учитывается в сортировке пользователя после проверки соответствия, а не повышает балл сходства товара.

FR-14. При расчёте экономии использовать сопоставимые наблюдения: одинаковые валюта, регион и условия. При несовпадении показать цены без процентной экономии.

5.5 Фильтры и экспорт

FR-15. Обязательные фильтры: площадка, режим соответствия, ценовой диапазон, минимальный балл, наличие, свежесть, обязательные характеристики. Дополнительные при наличии данных: бренд, рейтинг, количество отзывов.

FR-16. Фильтр «есть в наличии» исключает unknown. По умолчанию неизвестное наличие отображается отдельно. Условие на рейтинг исключает карточки с неизвестным рейтингом и сообщает это пользователю.

FR-17. Экспорт CSV UTF-8 содержит выбранные строки и поля, доступные в интерфейсе. Текстовые значения, начинающиеся с =, +, -, @, обезвреживаются для открытия в табличных программах. JSON-экспорт предоставляется через API.

FR-18. История хранит исходные параметры, версии правил, состав результатов и идентификаторы наблюдений. Изменение текущей цены не должно переписывать ранее показанный результат.

6 Подбор аналогов

6.1 Нормализация

Система очищает название от рекламных фраз, приводит регистр, пробелы, единицы измерения и написание брендов к согласованному виду. Нельзя удалять цифры модели, суффиксы версии, поколение и значимые обозначения. Оригинальные значения сохраняются рядом с нормализованными.

Для наушников базовые признаки: тип подключения, форм-фактор, назначение, модель, бренд, микрофон, активное шумоподавление, разъём, совместимость, автономность и состояние товара.

Цвет является значимым для точного варианта и настраиваемым ограничением для функционального аналога.

Единицы автономности приводятся к часам; сравнение наушников и суммарного времени с кейсом выполняется раздельно. «Шумоподавление микрофона» нельзя автоматически приравнять к ANC наушников. Маркетинговая надпись без подтверждённого поля сохраняется как исходный текст.

6.2 Режим точного совпадения

Совпадение подтверждается одинаковым достоверным GTIN либо брендом и точным артикулом/моделью с совпадением обязательных параметров варианта. Если обнаружено противоречие в модели, поколении, состоянии или комплектации, кандидат отклоняется независимо от похожежности названия.

При недостаточных данных результат обозначается «Возможное совпадение» и не попадает в группу подтверждённых точных совпадений. Точные и возможные совпадения представлены раздельно. Совпадение только бренда и общего названия не является достаточным основанием.

6.3 Режим функционального аналога

Сначала применяются жёсткие ограничения: категория, состояние, отсутствие принадлежностей и все обязательные условия пользователя. Кандидат с подтверждённым противоречием исключается. Кандидат с неизвестным обязательным полем показывается только в отдельной группе «Требуется проверка».

После этого вычисляется детерминированный балл 0–100. Балл отражает правила ранжирования, а не статистическую вероятность правильного ответа. Версия весов сохраняется в задаче.

Группа признаков	Начальный вес	Пример
Подключение	20	проводное, Bluetooth, радиоканал
Форм-фактор	20	TWS, полноразмерные, накладные
Назначение	15	повседневные, игровые, спортивные
Функции	20	микрофон, ANC, управление
Совместимость	10	разъём, платформы, ограничения
Количественные параметры	10	автономность, масса при наличии
Название и обозначение модели	5	лексическое сходство

По умолчанию марка не является обязательной для функционального аналога. Условие «тот же бренд» задаёт пользователь. Для MVP применяются словари правил, сравнение нормализованных полей и RapidFuzz для вспомогательного текстового сходства.

Для каждой группы вычисляется similarity_i от 0 до 1; подтверждённое совпадение — 1, частичное соответствие — значение по правилам категории, неизвестные данные — 0. Итог $S =$

$\text{sum}(\text{weight}_i \times \text{similarity}_i)$, где сумма весов равна 100. Дополнительно coverage = сумма весов групп, в которых существенные поля известны у обеих сторон, делённая на 100. Неизвестность не должна приводить к перенормировке весов и завышению оценки.

Начальные границы: S не менее 80 и coverage не менее 0,80 — высокая степень соответствия; S 65–79 и coverage не менее 0,65 — подходящий аналог; остальные прошедшие ограничения — группа ручной проверки. Границы калибруются на разработческой выборке до замораживания приёмочного набора. Если исходные поля неизвестны, запрос должен потребовать уточнение вместо создания уверенной выдачи.

6.4 Объяснение и обратная связь

Объяснение формируется шаблонами из сравнения полей: «Совпадают Bluetooth и TWS», «ANC отсутствует», «Автономность кандидата неизвестна». Оно не должно содержать фактов, отсутствующих в сохранённых данных.

Пользователь может подтвердить или отклонить аналог с причиной. Запись содержит пару карточек, режим, версию правил и дату. Обратная связь сохраняется для анализа и последующей настройки; автоматическое обучение и изменение правил без версии не входят в MVP.

7 Сбор данных и устойчивость

7.1 Порядок выбора источника

Для каждой площадки отдельно оценивается доступность официального разрешённого источника. API продавца не считается автоматически доступным источником поиска всего потребительского каталога. Если подходящего источника нет, используются доступные структурированные данные страниц и браузерное извлечение.

HTTP-загрузка предпочтительна, если она возвращает достаточные данные. Playwright применяется для динамических страниц и сохранённых браузерных сессий. Возможность доступа проверяется на реальных карточках до разработки полного подбора.

7.2 Работа с HTML

Адаптер должен разделять загрузку и извлечение. Парсер HTML можно запускать на сохранённом документе без сети для отладки и регрессионных тестов. Снимок исходного HTTP HTML и сериализованный DOM после JavaScript различаются; происхождение фиксируется.

При ошибке разметки сохраняются диагностические сведения и при необходимости обезличенный HTML-снимок с ограниченным сроком хранения. Полные снимки личного кабинета и cookies в общие журналы не записываются. После HTTP 403 запрещено интерпретировать страницу отказа как карточку товара.

7.3 Контракт адаптера

Каждый адаптер реализует: `can_handle(url)`, `fetch_product(url, context)`, `search_candidates(query, context)`, `parse_product(document)`, `parse_listing(document)`, `health_check()`. Результат — единая валидируемая модель, не HTML-селекторы в общем сервисе.

Ошибки классифицируются: `access_blocked`, `rate_limited`, `network_timeout`, `markup_changed`, `product_not_found`, `unsupported_category`, `session_expired`. Для каждой сохраняются площадка, стадия, HTTP-статус при наличии и безопасное диагностическое сообщение.

7.4 Ограничения обращений

Начальная конфигурация: одна активная браузерная задача на площадку и один процесс на профиль; пауза 2–4 секунды между навигациями; максимум две повторные попытки только для временных сетевых ошибок и HTTP 5xx. При 429 соблюдается Retry-After; при его отсутствии применяется увеличивающаяся задержка.

При 403 задача источника останавливается и переводится в blocked; автоматически многократно повторять такой запрос запрещено. Три последовательных access_blocked или markup_changed открывают защитный интервал источника на 30 минут. Доступно явное диагностическое повторение оператором. Эти настройки не гарантируют доступ и не заменяют правила площадки.

Сессии хранятся отдельно для каждого источника и оператора. Первый вход и проверки доступа допускают участие оператора. Пользовательское наличие ручных действий отражается в метрике автоматизации. Операции решения проверок доступа не выполняются скрыто от оператора.

7.5 Кеш и свежесть

Начальные TTL: поиск кандидатов — 6 часов, характеристики — 7 суток, цена и наличие — 24 часа. Все значения конфигурируемы. При повторном запросе обновляются только устаревшие части. Поиск по контексту с другим регионом либо условием цены не использует несопоставимый кеш.

Старый результат можно показать при ошибке обновления, но с явной отметкой возраста и причины. Он не участвует в заявлении об актуальной минимальной цене. Исчезновение из ограниченной выдачи не считается отсутствием в продаже.

8 Архитектура и реализация

8.1 Технологии

Компонент	Решение MVP
Backend и parsing	Python 3.12, FastAPI, Pydantic
Доступ к БД	SQLAlchemy 2, psycopg, Alembic
Хранилище	PostgreSQL 17 или 18, одна закреплённая версия
Браузер	Playwright с закреплённой версией и совместимым браузером
HTTP и HTML	HTTPX, BeautifulSoup либо lxml по фактической необходимости
Сопоставление	правила Python, RapidFuzz, конфигурации категорий
Web	Jinja2, HTML и CSS, минимальный JavaScript для статусов
Фоновые задачи	отдельный Python worker, очередь и расписание в PostgreSQL
Запуск	единый репозиторий, Docker Compose для API worker и БД
Проверки	pytest, сохранённые HTML, интеграционные проверки PostgreSQL

Версии зависимостей фиксируются lock-файлом и проверяются совместно. Синхронные операции Playwright выполняются в worker, а не в обработчике HTTP API. Блокирующий парсинг не должен задерживать веб-запросы.

8.2 Состав модулей

Модули: `api`, `web`, `adapters`, `matching`, `normalization`, `repository`, `jobs`, `config`, `tests`. Адаптеры не выполняют произвольную запись в БД; сервис сценария вызывает `repository`. Проверки правил сопоставления запускаются без браузера.

В исходном `ozon_parser.py` сохраняются проверенные функции нормализации, но разделяются CLI, браузер, извлечение и сохранение. Диагностические `check_browser.py` и `check_habr_browser.py` остаются инструментами разработчика. Их настройки не становятся обязательными зависимостями продукта.

8.3 Фоновые задачи

API создаёт запись `Job` и немедленно возвращает её ID. Worker атомарно выбирает готовую задачу через `FOR UPDATE SKIP LOCKED`, устанавливает `owner_token` и срок аренды, фиксирует транзакцию и только после этого выполняет сетевую работу.

Статусы задачи: `queued`, `running`, `needs_input`, `succeeded`, `partial`, `failed`, `cancelled`. Статусы отдельных источников: `pending`, `running`, `succeeded`, `blocked`, `failed`, `cached`. Ожидание уточнения пользователя не занимает браузерный слот. Автоматического бессрочного ожидания Enter в серверном worker быть не должно.

Аренда задачи — 120 секунд, heartbeat — каждые 30 секунд; исполнитель проверяет `owner_token` при записи итогов. Просроченные задачи возвращаются в очередь, максимум три исполнения. Запись идемпотентна; уникальные ключи исключают дубли наблюдений. Планировщик внутри единственного worker создаёт задачи по `next_refresh_at` и уникальному ключу карточки/контекста/окна обновления.

Для MVP не требуется Celery или Redis. FastAPI `BackgroundTasks` не используется как единственное хранилище критичных задач. Постоянная очередь PostgreSQL обеспечивает переживание перезапуска. При росте нагрузки контракт `Job` позволяет заменить механизм исполнения без изменения API.

9 Модель PostgreSQL

9.1 Основные сущности

Сущность	Содержание и ограничения
Marketplace	code уникален, название, <code>base_url</code> , состояние адаптера
Brand	нормализованное имя и управляемые варианты написания
Category	общая категория, <code>parent_id</code> , правила и версия конфигурации
Product	подтверждённый общий товар и вариант, GTIN, модель, атрибуты
Listing	площадка, внешний ID, URL, название, нормализованные признаки, <code>product_id</code> при доказанном соответствии
Observation	карточка, время, регион, условие, валюта, цена, наличие, рейтинг, отзывы и происхождение
ScrapeRun	стадия сбора, версия адаптера, источник, время и статус

Сущность	Содержание и ограничения
MatchRequest	входные параметры, режим, исходная карточка или ручные поля, версия правил, итоговый статус
MatchResult	исходная карточка/снимок, кандидат, ссылки на наблюдения, score, coverage, класс, причины и различия
Job	тип, payload, статус, попытки, scheduled_at, owner_token, lease_until, heartbeat и ошибка
Feedback	оценка пользователя пары товаров и причина
WatchItem	избранная карточка, контекст, период и next_refresh_at

Пользовательские ограничения и исходные поля сохраняются в MatchRequest как неизменяемый снимок. MatchResult должен содержать версию правил и признаки, на которых сделан вывод, чтобы последующее изменение карточки не меняло объяснение старого результата.

9.2 Правила хранения

Цена — NUMERIC(14,2), в Python Decimal; время — TIMESTAMPTZ с моментом фактического получения; внешний ID — TEXT. Уникальность Listing — (marketplace_id, external_id). Валюта, region_key, price_kind и condition_key обязательны; unknown допускается явно.

Цена NULL означает отсутствие достоверной цены. availability имеет значения in_stock, out_of_stock, unknown. Исходные строки и дополнительные признаки хранятся в JSONB; ключи, типы и единицы нормализованных признаков едины для площадок. Постоянное содержимое профиля не хранится в PostgreSQL.

Карточка из выдачи не всегда определяет продавца. Модель Seller/Offer не обязательна для MVP. Когда продавец и отдельное предложение достоверно доступны, их ID сохраняются; отсутствие этих данных обозначается явно и не позволяет утверждать сравнение всех продавцов.

9.3 Актуальные значения и индексы

Начальный вариант — представление latest_observation с выбором последнего наблюдения по карточке, региону, валюте и условию. Последнее NULL или out_of_stock не должно заменяться более старой удобной ценой.

Индексы: уникальность площадки/ID; product_id; категория и бренд; история по карточке/контексту/времени; Job по статусу и scheduled_at; MatchResult по запросу и рангу; GIN для JSONB; pg_trgm для поиска по нормализованному названию. Избыточные индексы добавляются только после измерения запросов.

Поисковая выдача использует keyset-пагинацию с устойчивым дополнительным ключом ID. Для MVP допускается LIMIT/OFFSET при ограниченных 20 итоговых позициях одного запроса. Результаты разных валют не сортируются общей числовой ценой без явного преобразования; конвертация валют в MVP не требуется.

9.4 Хранение и восстановление

Результаты запросов и наблюдения сохраняются минимум 90 дней. Диагностический HTML — максимум 7 дней и только по необходимости. Ограничения объёма и очистка задаются конфигурацией. Избранные ссылки и подтверждённые соответствия сохраняются до удаления владельцем.

Ежедневная резервная копия PostgreSQL, хранение последних семи копий вне основного каталога данных. Требуемая потеря данных при аварии — не более 24 часов, восстановление — не более четырёх часов. Приёмка включает восстановление из резервной копии на чистой БД.

10 API

10.1 Обязательные методы

Метод и адрес	Назначение
POST /api/v1/match-requests	Создать задачу по URL либо ручным полям
GET /api/v1/match-requests/{id}	Получить статус, прогресс, ошибки источников
PATCH /api/v1/match-requests/{id}/input	Дополнить характеристики в needs_input
GET /api/v1/match-requests/{id}/results	Выдача с фильтрами и сортировкой
POST /api/v1/match-requests/{id}/retry	Повторить выбранные неуспешные источники
POST /api/v1/match-requests/{id}/cancel	Запросить отмену незавершённой задачи
POST /api/v1/feedback	Подтвердить либо отклонить аналог
POST /api/v1/watch-items	Добавить карточку к плановому обновлению
GET /api/v1/watch-items	Получить избранные карточки
DELETE /api/v1/watch-items/{id}	Отключить обновление
GET /api/v1/match-requests/{id}/export	Экспорт CSV или JSON
GET /api/v1/sources	Состояния адаптеров и последняя проверка
GET /health/live и /health/ready	Работа процесса и доступность БД

Создание возвращает HTTP 202, request_id и status_url. Повтор при одинаковом Idempotency-Key в пределах 24 часов возвращает прежний ID; другой payload с тем же ключом отклоняется. Отмена проверяется между стадиями и навигациями; принудительное завершение по таймауту не должно повредить сохранённые данные.

Ошибки API имеют единый формат: code, message, request_id, details. HTTP 422 обозначает недопустимый ввод, 401 — отсутствие авторизации, 404 — неизвестную запись, 409 — конфликт состояния, 429 — превышение лимита API. Ошибка 403 внешней площадки представляется статусом источника, а не отказом доступа пользователя к собственному API.

10.2 Содержимое результата

Вход: `source_url` или `manual_product`, `mode`, `target_marketplaces`, `region_key`, `required_attributes`, `optional_preferences`, `price_range` и `freshness_limit`. Одновременный конфликтующий URL и `manual_product` не допускается.

Выход позиции: `listing_id`, `marketplace`, `title`, `url`, `match_type`, `score`, `coverage`, `matched_attributes`, `differences`, `missing_attributes`, `observation_id`, `price`, `currency`, `price_kind`, `condition_key`, `availability`, `observed_at` и `freshness_status`. Decimal в JSON передаётся десятичной строкой. Полное описание OpenAPI входит в поставку.

11 Веб и развитие интерфейсов

11.1 Веб MVP

Страницы: форма подбора; уточнение исходных характеристик; ход и результат; история; избранное; состояние источников. Требуется корректная работа на ширине от 360 пикселей и в актуальном Chrome. Таблица результатов на узком экране преобразуется в карточки.

Начальная форма содержит ссылку, режим и свёрнутые дополнительные фильтры. Интерфейс не показывает селекторы, `browser flags` и внутренние SQL-поля. У каждой ошибки есть пользовательское действие: исправить ссылку, уточнить поля, повторить источник или обратиться к оператору.

Получение статуса выполняется опросом раз в 2 секунды только для открытой активной задачи. После завершения опрос прекращается; при скрытой вкладке интервал увеличивается. WebSocket в MVP не требуется.

11.2 API как самостоятельный интерфейс

API использует тот же сервис сценария, что и веб. Подключение новых клиентов не должно создавать отдельную реализацию подбора. Документация примеров запросов и ошибок обязательна.

11.3 Расширение Chrome после MVP

Расширение получает URL открытой карточки, отправляет его в существующий API и показывает ссылку на результат. Логика парсинга и ранжирования остаётся в backend. Для первой версии расширения не требуется автоматический сбор cookies либо чтение личного кабинета.

Минимальные разрешения — действия пользователя над текущей вкладкой и доступ к адресу API. Расширение не включается в критерии приёмки MVP; его разработка начинается после подтверждения качества и доступности источников.

12 Нефункциональные требования

12.1 Производительность

Базовый испытательный стенд: 4 vCPU, 8 ГБ RAM, SSD; PostgreSQL, API и один worker. Нагрузочный профиль: 10 одновременных пользователей, не более одной активной задачи на источник, очередь максимум 100 задач, база 100 тысяч карточек и 1 миллион наблюдений.

Для чтения локальных данных p95 API не более 1 секунды; создание задачи p95 не более 500 мс. Для свежего кеша результат доступен не более чем за 2 секунды. Для новой задачи целевой p95

— 180 секунд от старта исполнения при доступных источниках; ожидание очереди и ручное уточнение измеряются отдельно.

Общий предельный срок одного исполнения — 300 секунд. Невыполненные источники переводятся в ошибку или `partial`, процесс не зависает бессрочно. Эти пределы не являются гарантией времени ответа маркетплейсов.

12.2 Надёжность

Перезапуск API не теряет Job; перезапуск worker позволяет восстановить задачу после истечения аренды. Авария посередине записи не оставляет частично записанную карточку без обязательных связей. Повтор одной задачи не создаёт дубли наблюдений.

При недоступности БД API ready возвращает неуспех; worker не продолжает сбор без возможности безопасно сохранить состояние. Ограничение очереди возвращает 429 с объяснением, а не бесконечно накапливает задачи.

12.3 Безопасность

MVP использует одного владельца установки: пароль с устойчивым хешированием и серверная сессия для веб, отдельный API-токен для интеграций. При внешнем размещении обязателен HTTPS. Cookies сессии защищены HttpOnly, SameSite и Secure в HTTPS; изменяющие веб-запросы защищены от CSRF.

Внешние URL разрешены только для согласованных доменов площадок. Запрещаются localhost, приватные/служебные адреса, пользовательские credentials, file/data/javascript и произвольные порты. Каждый HTTP-редирект и адрес сетевого подключения проверяется заново; браузер работает в ограниченном окружении без доступа к внутренним сервисам и метаданным облака.

Результаты и сообщения экранируются в HTML. SQL выполняется с параметрами. Секреты читаются из окружения и не публикуются в репозитории, экспортах и журналах. Профили Chromium доступны только оператору и worker. API допускает создание не более 10 задач в минуту на владельца; лимит конфигурируемый.

12.4 Наблюдаемость

Структурированные журналы содержат request_id, job_id, run_id, источник, стадию, длительность и код ошибки. Секретные query-параметры, пароль, cookies и содержимое авторизации удаляются. Метрики: длина очереди, возраст задач, успех/partial/ошибки, 403/429, длительность, cache hit, ручные вмешательства и количество кандидатов на стадиях.

Для MVP достаточно страницы состояния и структурированных файлов журналов с ротацией. Отдельные Prometheus/Grafana не обязательны. Метрики качества рассчитываются контрольным скриптом и сохраняются отчётом для каждой версии правил.

13 Проверки качества и приёмка

13.1 Контрольный набор

До настройки алгоритма заказчик и исполнитель фиксируют 60 сценариев в категории наушников, минимум по 20 исходных карточек каждой площадки. 20 сценариев используются для настройки; оставшиеся 40 — только для итоговой приёмки. В каждом приёмочном сценарии должен существовать хотя бы один заранее подтверждённый доступный аналог на другой площадке.

Для кандидатов размечаются минимум 300 пар, включая минимум 100 положительных, 30 сложных отрицательных и 30 пар точных вариантов. К отрицательным относятся принадлежности, другая модель/поколение, несовместимый разъём, обязательная отсутствующая функция и б/у вместо нового. Одна пара может участвовать в нескольких соответствующих поднаборах.

Пары размечаются человеком с доступом к карточкам и кратким обоснованием. Спорные пары согласуются отдельно. Фиксируются дата, регион, условия цены, исходные снимки и версии; после просмотра итоговых метрик нельзя менять приёмочные метки без документированного исправления ошибки.

13.2 Метрики

Precision@5 для сценария — доля релевантных среди реально показанных первых пяти результатов. Если результатов меньше пяти, знаменатель равен их количеству; пустая выдача на сценарии с известным аналогом имеет значение 0. Итог — среднее по 40 сценариям, не ниже 0,90. Чтобы короткая выдача не маскировала недостаток поиска, отдельно применяется Hit@5.

Hit@5 — доля приёмочных сценариев с хотя бы одним релевантным результатом в первых пяти: минимум 34 из 40. Полнота получения кандидатов измеряется только относительно фиксированного набора эталонных аналогов, а не всего каталога; минимум 85% доступных эталонных карточек должны попасть в кандидаты.

Для режима точного совпадения: ноль ложных подтверждённых совпадений на всех размеченных точных и конфликтующих парах; на положительном поднаборе подтверждено не менее 80% пар с достаточными идентификаторами. Недостаточные данные нельзя обходить выдачей ложной уверенности.

13.3 Пилот автоматизации

Выполнить не менее 50 новых допустимых задач в течение трёх календарных дней. Зафиксировать общий процент успеха, процент задач без вмешательства, доступность каждой площадки и причины отказа. Для условной метрики при доступных источниках минимальный объём — 30 задач, не менее 90% без вмешательства.

403, 429 и изменения разметки учитываются в общей статистике. Если любая согласованная площадка систематически недоступна и не проходит пилот, полная приёмка MVP откладывается либо состав источников изменяется согласованной версией ТЗ. Частично работоспособные адаптеры не считаются выполнением требования трёх площадок.

13.4 Матрица испытаний

Код	Проверка	Условие успешной приёмки
АТ-01	Получение исходной карточки	Данные трёх площадок валидируются, неизвестность сохраняется явно
АТ-02	Точное совпадение	Выполнены показатели поднабора и нет ложной уверенности
АТ-03	Аналоги	Precision@5, Hit@5 и полнота кандидатов достигнуты
АТ-04	Различия вариантов	Модель, комплект, состояние и обязательные поля корректно ограничивают выдачу
АТ-05	Цена и контекст	Условия цены видны, несопоставимая экономия не вычисляется

Код	Проверка	Условие успешной приёмки
AT-06	Ошибка одного источника	Доступные результаты сохранены, статус partial, причина видна
AT-07	Повтор и кеш	Нет дублирующих активных задач и лишнего сбора свежих данных
AT-08	Перезапуск worker	Аренда восстанавливается, повтор не дублирует записи
AT-09	Безопасность	Отклонены запрещённые URL и редиректы, HTML экранируется, секретов в журнале нет
AT-10	Web и CSV	Полный сценарий на desktop/mobile, корректная выгрузка
AT-11	Резервная копия	Восстановлены данные на чистом экземпляре PostgreSQL
AT-12	Производительность	Выполнены установленные p95 на испытательном стенде
AT-13	Пилот	Отчёт 50 задач, выполнены требования автоматизации и источников

13.5 Виды тестов

Модульные: нормализация, единицы, URL, цена, фильтры и правила сопоставления. Контрактные: каждый адаптер на сохранённых HTML разных видов страницы. Интеграционные: реальный PostgreSQL, миграции, внешние ключи, идемпотентность, очередь и выбор актуального наблюдения. Сквозные: форма → задача → worker → результаты → экспорт.

Живые обращения выполняются ограниченно и отдельно от обычного CI. Для воспроизводимых тестов применяются сохранённые документы и ответы; нарушение доступа к площадке не ломает офлайн-проверки алгоритма. Один HTML-пример на площадку недостаточен: нужны карточка, выдача, отсутствие цены, неизвестное поле и страница отказа.

14 Порядок разработки

14.1 Этапы

Этап	Результат	Предварительные трудозатраты
1 Проверка доступа	Три источника, исходные карточки и HTML, решение по рискам	2–3 рабочих дня
2 Общие модели	DTO, PostgreSQL, миграции, repository, тестовые документы	2–3 рабочих дня
3 Адаптеры	Поиск и карточка для трёх площадок, ошибки и кеш	5–7 рабочих дней
4 Подбор	Правила категории, точное совпадение, аналоги, объяснения	3–4 рабочих дня
5 API и web	Основной маршрут, фоновые задачи, фильтры, экспорт	4–5 рабочих дней

Этап	Результат	Предварительные трудозатраты
6 Проверка и поставка	Пилот, метрики, исправления, резервные копии, инструкции	4–6 рабочих дней

Суммарный ориентир — 20–28 рабочих дней одного разработчика, знакомого с Python и PostgreSQL. Оценка не включает ожидание доступа, решения блокировок, согласование разметки и расширение категорий. Календарный срок утверждается после этапа 1. Указанные числа не являются обязательством о сроке без проверки источников.

14.2 Контрольная точка доступа

До разработки сложного ранжирования подтвердить для каждой площадки: получение исходного товара, поиск по модели, получение цены и характеристик, повторный запуск с отдельной сессией и допустимый режим обновления. Если Ozon продолжает возвращать 403, нельзя считать, что смена селектора либо внедрение БД устранил блокировку.

По результатам этапа оформляется решение: доступный автоматический источник; режим с редким участием оператора; замена источника; изменение границ продукта. Исключение площадки требует согласования, поскольку меняет назначение трёхплощадочного MVP.

14.3 Использование существующего проекта

Существующий парсер рассматривается как прототип, а не готовый адаптер продукта. Перенести проверенные функции цены и URL, добавить извлечение карточки отдельного товара, отделить загрузчик от HTML-парсера и заменить JSON как единственное хранилище общим repository. Сохранять external_id, Decimal, observed_at и происхождение данных.

Существующий docs/schema.sql является исходной моделью. Для ТЗ требуются дополнительные таблицы MatchRequest, MatchResult, Job, Feedback и WatchItem; изменения оформляются миграциями Alembic, а не ручным редактированием рабочей БД.

15 Сокращение трудозатрат и оптимизация

15.1 Обязательные решения MVP

- Одна предметная категория с проверяемыми правилами вместо немедленной поддержки всех товаров.
- Один репозиторий, один backend и один worker; PostgreSQL одновременно хранит очередь и результаты.
- Jinja2 и минимальный JavaScript вместо отдельного frontend-проекта.
- Локальные правила и словари вместо обязательного обучения модели и оплаты внешних запросов.
- Сначала кеш и данные выдачи, затем ограниченное открытие лучших карточек.
- Общий контракт адаптеров и единое сохранение вместо копирования всего парсера для площадки.
- Раздельные TTL характеристик и цен, плановое обновление только избранного.
- Офлайн HTML-фикстуры для быстрой проверки разметки.

- Уточнение пользователя для неизвестных обязательных полей вместо недостоверной автоматической уверенности.

15.2 Что нельзя сокращать

Нельзя исключать условия цены, историю времени, проверку конфликтов вариантов, устойчивость очереди, объяснение результата и контрольный набор. Эти функции формируют доверие к подбору; их отсутствие превращает продукт в список похожих названий.

Для MVP допускаются простое оформление веб-страницы, один владелец и базовая эксплуатационная панель. Добавление сложной инфраструктуры допускается только при измеренном ограничении производительности или новых требованиях.

16 Риски и ограничения

Риск	Последствие	Предусмотренная мера
Блокировка 403 либо сессии	Не удаётся получить свежие данные	Ранний этап доступа, отдельный статус, без бесконечных повторов
Изменение DOM	Ошибки полей либо пустая выдача	HTML-фикстуры, контрактные проверки, остановка адаптера
Недостаток характеристик	Ошибочный аналог	Уточнение, coverage, запрет уверенного вывода
Карта и персональные цены	Неверная экономия	Контекст цены и ограничение сравнения
Похожие модели и комплекты	Ложное точное совпадение	Жёсткие конфликты и отрицательные примеры
Небольшая контрольная выборка	Завышенное качество	Отдельная приёмочная выборка и пилот
Отсутствие аналога в просмотренной выдаче	Ложный вывод об отсутствии	Сообщение об ограниченности поиска
Рост браузерной нагрузки	Очередь и превышение RAM	Лимиты, кеш, ограниченное число карточек

Полнота всего каталога и постоянная доступность сторонних площадок не гарантируются. Система должна точно сообщать границы поиска, дату и основание вывода, а не обещать найти все существующие предложения.

17 Состав поставки и приёмочные документы

Исполнитель передаёт исходный код с инструкцией запуска, закреплённые зависимости, Docker Compose, конфигурационный пример без секретов, миграции, OpenAPI, инструкции пользователя и оператора, HTML-фикстуры, контрольный набор, результаты тестов и пилота, инструкции резервного копирования и восстановления.

Поставка содержит пример запроса и результата для каждой площадки и оба режима подбора. На чистой среде выполняются установка, миграции, создание владельца и сквозной

демонстрационный сценарий. Профили браузера и реальные пароли в архив исходников не включаются.

Приёмка оформляется протоколом с перечнем АТ-01–АТ-13, версиями адаптеров и алгоритма, условиями стенда, метриками и замечаниями. Открытые замечания классифицируются как блокирующие, значимые либо косметические. Блокирующие: потеря данных, невозможность основного сценария, ложные подтверждённые совпадения, скрытая несопоставимость цен, нарушение доступа и систематическая недоступность согласованного источника.

18 Последующее развитие

После подтверждения MVP добавляются новые категории с собственными признаками и выборками, Chrome-расширение, уведомления о снижении цены, многопользовательские аккаунты и предложения продавцов. Векторный поиск либо LLM рассматриваются только после анализа ошибок правил и оценки дополнительной стоимости; они не заменяют жёсткие проверки характеристик.

Масштабирование предусматривает отдельные workers, более развитую очередь и таблицу текущих наблюдений при доказанной необходимости. Контракты API, Job и адаптеров должны сохраниться. Любое расширение сопровождается новой версией ТЗ и повторной проверкой качества соответствующей категории.

Приложение А Источники технических решений

1. FastAPI — шаблоны и Jinja2: <https://fastapi.tiangolo.com/advanced/templates/>
2. FastAPI — фоновые задачи и ограничения: <https://fastapi.tiangolo.com/tutorial/background-tasks/>
3. PostgreSQL — SELECT и SKIP LOCKED: <https://www.postgresql.org/docs/current/sql-select.html>
4. PostgreSQL — типы и JSONB: <https://www.postgresql.org/docs/current/datatype-json.html>
5. PostgreSQL — pg_trgm: <https://www.postgresql.org/docs/current/pgtrgm.html>
6. Playwright Python — BrowserType и отдельные профили:
<https://playwright.dev/python/docs/api/class-browsertype>

Документ использует формальную структуру технического задания: назначение, требования, этапы, испытания и поставка. Соответствие конкретному ГОСТ или корпоративному шаблону должно оформляться отдельно при наличии такого требования заказчика.